okb • openKylin 智能体长期记忆自动化评测 Benchmark

> 作品介绍文档 · v2.0-R12 提交版 · 2026-10-16 配套：代码仓库（含完整可运行代码与真实运行证据）、演示视频（4 分 39 秒）、方案说明文档 a、样例包 b、复现材料 c、deb 工具包 d。

一、项目背景

大模型智能体正在进入办公、研发与个人助理场景，"能否长期、稳定、可控地记住用户信息"成为影响智能体可用性的关键能力。长期记忆既包括**应被保留**的稳定信息（偏好、路径、模板），也包括**应被识别并排除**的临时信息、敏感信息、风险指令与噪声。

当前 openKylin 生态已支持 OpenClaw、Hermes、KylinBot 等主流智能体框架，但缺少与之配套的**系统级自动化评测工具**，行业现状存在三大痛点：

1. **依赖人工检查，难以规模化**——记忆能力评测往往靠人看轨迹、翻文件；
2. **简单问答式验证覆盖不足**——无法覆盖真实使用中的冲突更新、相似干扰与行动复用；
3. **自动评分语义偏移**——难以稳定判断模型到底是"记住了""误记了"还是"不该记却记了"。

okb 的目标：在 openKylin 上，对通用智能体的长期记忆能力做**自动化、低人工、可复现、可扩展**的量化评测，产出多维指标（六维 + 覆盖率 + 风险指标）与**逐条可解释**的评分原因，用于跨智能体比较与持续优化。

二、技术架构

2.1 总览

```
被测 Agent（多款 · 适配器契约）
   │  引擎：清场 → 布置 → 发题 → 取证
   ▼
证据层：事件索引 evidence.jsonl + raw 真身（逐轮进程输出 / 记忆前后快照 / 文件差分）
   ▼
双轨评分：客观锚点（规则可复算） + 语义判官（三态判定 + 引用强约束）
   ▼
四层聚合：证据门 → 客观检查 → 语义检查 → 聚合与复核队列
   ▼
指标与报告：六维通过率 + 覆盖率 + 风险指标 + 雷达图 + 逐检查解释（结论/理由/引文）
```

2.2 核心组件

组件	职责
`engine/`	任务级清场、发题、逐轮独立进程调用、记忆/文件/回复取证（带扫描范围自证）

组件	职责
适配器契约	引擎只发通用动作；适配器翻译成各 Agent 的 CLI 与文件布局（OpenClaw / Hermes / `cli_template` 声明式接入新智能体）
`v2/`（卷与计划）	92 道多会话记忆题的确定性生成链：作者稿 → 计划 → 装配 → lint → 断言库（629 槽位）
四层评分器	证据门 → 客观检查 → 语义判官（gpt-6.1-sol）→ 聚合；请求精确回放、预算账本
判词防线	极性/自足性 lint（E201/E202 阻断级）；引用校验不过=弃权；答案隔离
`okb` CLI + `.deb`	一键跑批/评分/报告；`agents.yaml` 导入不同智能体配置批量对比；openKylin 实测安装可用

2.3 关键工程机制

- **运行证据统一取证**：每个任务产出三层证据（事件索引、raw 真身、档案台账），记忆快照带扫描范围自证——"证据不是转述，是可审计的原件"；
- **可复现性**：同计划同请求**零调用回放**，评分结果与冻结值逐字节一致；openKylin VM 与宿主跨机复现一致；
- **稳定性证据**：同计划两轮 A/A，请求级翻转 1.25%（决定性翻转仅 0.12%），单批结论可引用；
- **字节冻结**：全仓换行/编码冻结（`* -text`），判官记录与输入指纹锁（input-lock）绑定。

三、应用场景

场景	用法与价值
openKylin 社区横评	同一套题、同一证据口径，对生态内多款智能体做可比的长期记忆能力评级
智能体开发回归	发版/调参前后跑记忆回归，用差异定位"哪条记忆坏了"；逐检查解释直接指向证据原文
持续评测（CI）	`okb run` + 评分回放全离线可编排；批次数百任务分钟—小时级产出多维报告
研究与选型	六维通过率 + 覆盖率 + 风险指标并列；不刷单一总分，"不可判"如实披露
敏感场景验证	边界识别维（临时信息/敏感信息/风险指令）检验智能体的"该忘"与"该拒"能力

四、创新点

1. **运行证据驱动的自动评分，而非问答对错**：引擎统一组织对话、记忆、文件、行动轨迹为证据，自动判定**记住 / 遗漏 / 混淆 / 错误持久化 / 错误复用**五分类；
2. **判官可解释性硬约束**：语义判官必须给出真实证据编号 + JSON Pointer + 原文引用，引用校验不通过即**弃权**（而不是猜）；判官看不到答案标签（答案隔离）；
3. **判词极性机器防线**：requirement 一律归一化为"合规命题 + 显式映射"（94 条改写台账），极性/自足性由阻断级 lint 把关——从机制上消灭"判反了"这类系统性错误；
4. **少人工的可信度工程**：判官在正常链路零人工；人工只做**验证**——A/A 稳定性 + 检查项级盲审（AI 预筛 + 人工裁决单裁 48 例，人机一致 91.7%、κ 0.76、**0 假通过**）；

5. **诚实指标口径**：双口径披露（可判口径 + "不可判按失败"下界）、覆盖率门槛（不足只进雷达）、风险指标单列；"采不到 ≠ 没记住"；
6. **全链路离线可复现 + 多智能体可扩展**：零调用评分回放逐字节一致；openKylin 跨机验证；一键 CLI/.deb；`cli_template` 声明式接入第三个及以后的智能体。

五、成效（本批实测）

指标	数值
数据集	92 道多会话记忆题（六维配额；含动态更新 15、相近区分 15、任务复用 17）
真实运行	552 任务（92 题 × 2 Agent × 3 轮），证据有效 552/552
自动评分	1674 条语义检查全量判定；零调用回放结果与冻结值**逐字节一致**
数据质量校准	高区分 23 / 饱和 30 / 地板 9（item 台账）
判官稳定性	A/A 请求级翻转 1.25%（决定性 0.12%）
人机校准	单裁 48 例：一致 91.7%（κ 0.76），0 假通过、2 误杀（已登记修订）、2 弃权
工程	921 项测试全绿；复算链 54 产物 0 漂移；`.deb` openKylin 实测安装可用

> **边界声明（如实披露）**：本批为探索性诊断——人审为单裁 48 例（AI 预筛 + 人工裁决，无第二人 κ）；覆盖率不足维度只进雷达；时间纵深/敏感样本偏薄。路线图与限制详见数据卡与方案说明文档。

六、交付物与复现入口（赛题 a–e 对照）

赛题要求	交付物	位置
a 方案说明文档	测试目标/基本前提/数据生成/用例设计/结果收集/自动评分流程 + 核心要素（可扩展数据结构、少人工可解释评分）	`deliverables/a-方案说明文档.md`
b 样例数据与样例结果	3 个真实案例：任务 + 证据切片 + 逐检查评分解释 + 复现命令	`deliverables/b-样例包.md` → `v2/07-deliverable-b/`
c 可复现材料	开发机 + openKylin 双路线复现说明；回执（链重建同 sha、评分重放逐字节一致、deb 安装可用）	`deliverables/c-复现说明.md` + `c-openkylin-verify/receipt.md`
d 工具化封装	`okb` 一键 CLI + `.deb` 软件包（内容指纹跨机可比）；`agents.yaml` 批量对比	`deliverables/d-工具封装.md` + `d-package/`
e 真实环境演示视频	openKylin 桌面：环境证明 → 进程监视 → 双 Agent 真实运行（双窗：运行 + 实时监视）→ 评分回放 → 判定解释 → 六维雷达	`deliverables/recording-2026-10-16.mp4`（4:39）

复现入口（仓库根目录，详见交付 c）：

```
python v2/02-generators/build_stock_v2.py && python v2/02-generators/assemble_v2.py  # 应输出
卷 sha bca2c68c…
python tools/plan_lint.py --plan v2/01-paper-v2/paper-v2.plan.json                   # 0 error
python -m pytest tools/tests engine/tests -q                                        # 921
passed
python tools/score_four_layer.py --replay score/judge-full-3/records.jsonl …        # 零调用
回放 → results sha afc8b73a…
```

七、路线图（v2.1）

时间跨度题 2（跨 ≥2 日历月）+ 敏感题 2–3 + 深轮次槽 2–3（单会话 12–20 轮）+ 深会话链 1–2 + 干扰对 1–2 + 构念审计 + 记忆面探针 + 双人人审 ≥50 例（κ）。